



Université Euromed de Fès

École d'Ingénierie Digitale et Intelligence Artificielle

Rapport du Travail Pratique :

Pipeline OLTP - ETL PDI - Data Warehouse - Reporting Power BI

Cas de l'entreprise fictive TechStore

Préparé par : Nada Ezzouhour EL ACHABI

Date : 26 Novembre 2025

Résumé exécutif

Le présent rapport décrit de manière exhaustive la conception, la mise en œuvre et l'exploitation d'une solution de Business Intelligence (BI) dédiée à l'entreprise fictive TechStore, un distributeur de produits électroniques présent dans plusieurs régions. Dans un contexte où les entreprises génèrent de plus en plus de données grâce à la digitalisation de leurs activités, la capacité à transformer ces données brutes en informations exploitables devient un avantage concurrentiel essentiel.

Le projet a été mené dans une démarche complète : depuis la modélisation d'une base opérationnelle OLTP qui simule les activités quotidiennes de TechStore, jusqu'à la création d'un Data Warehouse et la mise en place d'un processus ETL automatisé via Pentaho Data Integration, en passant par la génération de données réalistes et l'implémentation de visualisations analytiques interactives dans Power BI. Ce rapport présente l'intégralité de ces étapes de manière détaillée, pédagogique et structurée.

L'objectif principal consiste à permettre aux décideurs de TechStore d'obtenir des indicateurs clés de performance (KPI) fiables, pertinents et mis à jour, afin d'améliorer la qualité de la prise de décision. Grâce à l'exploitation du Data Warehouse ainsi construit, TechStore peut analyser les ventes par mois, par produit, par région, mais aussi identifier les clients les plus rentables, les catégories dominantes et les tendances de marché.

Le projet démontre la pertinence d'une approche BI moderne pour répondre aux problématiques rencontrées par TechStore : difficulté à analyser l'évolution des ventes, manque de visibilité sur la performance géographique, absence d'outils consolidés pour suivre le chiffre d'affaires, etc. La solution BI permet enfin d'agréger, d'organiser, d'historiser et d'exploiter les données de manière cohérente et structurée.

Introduction générale

0.1 Importance stratégique de la Business Intelligence

Dans le contexte économique actuel, caractérisé par une concurrence accrue, une volatilité des marchés et une digitalisation massive, la donnée est devenue une ressource stratégique. Les entreprises génèrent aujourd'hui des volumes colossaux d'informations via leurs systèmes opérationnels, plateformes web, interactions clients, objets connectés, réseaux sociaux, ERP, CRM et autres outils digitaux. Cependant, la véritable valeur de ces données n'est exploitée que si elles sont correctement collectées, stockées, nettoyées, structurées et restituées.

La Business Intelligence (BI) regroupe ainsi les technologies et méthodes permettant cette transformation. Elle joue un rôle clé pour :

- comprendre les tendances du marché,
- détecter les opportunités commerciales,
- anticiper les risques,
- optimiser les processus internes,
- améliorer l'expérience client,
- orienter les décisions stratégiques.

0.2 Évolution des systèmes d'information décisionnels

Historiquement, les entreprises s'appuyaient sur des rapports statiques, construits manuellement à partir de données extraites ponctuellement. Ces pratiques se révèlent aujourd'hui insuffisantes, voire contre-productives :

- un temps de production important,
- des risques d'erreur,
- une absence d'historisation,
- une difficulté à analyser plusieurs périodes simultanément,
- une impossibilité de consolider plusieurs sources.

Avec l'arrivée des Data Warehouses, des systèmes ETL et des outils analytiques, les systèmes décisionnels sont devenus plus efficaces, automatisés et fiables.

0.3 Objectifs du projet TechStore

L'objectif global du projet est d'établir une chaîne décisionnelle complète permettant de transformer les données opérationnelles brutes en informations utiles à la prise de décision. Les objectifs spécifiques sont :

1. Concevoir un modèle OLTP normalisé.
2. Générer des données simulant plusieurs mois d'activité.
3. Concevoir un Data Warehouse robuste.
4. Définir un schéma en étoile optimisé.
5. Mettre en place un pipeline ETL automatisé.
6. Effectuer des analyses OLAP pertinentes.
7. Construire un tableau de bord interactif dans Power BI.

0.4 Présentation détaillée de TechStore

TechStore est une entreprise spécialisée dans la distribution de produits électroniques, possédant un réseau de magasins répartis dans différentes régions du pays, ce qui lui permet de toucher une clientèle variée et de répondre à des besoins diversifiés.

Chapitre 1

Organisation générale

Elle comporte plusieurs départements :

- Département commercial,
- Département marketing,
- Département logistique,
- Département achat,
- Service après-vente,
- Direction stratégique.

Le système opérationnel de TechStore permet d'enregistrer les ventes, de gérer les clients, les produits, les stocks et les magasins et même suivre leurs performances.

1.1 Problèmes rencontrés sans BI

TechStore faisait face à :

- absence de vision consolidée,
- difficulté d'analyse multi-périodes,
- incohérences dans les données,
- impossibilité de comparaison géographique,
- rapports manuels chronophages,
- identification difficile des produits rentables.

1.2 Étude approfondie des besoins décisionnels

La réussite d'un projet décisionnel repose en grande partie sur la qualité de l'analyse des besoins métier. Cette étape, souvent sous-estimée, est pourtant cruciale : elle conditionne la conception du modèle de données, la création des indicateurs et la pertinence des tableaux de bord. Dans le cas de TechStore, une étude minutieuse des besoins a révélé plusieurs axes d'analyse essentiels, liés à la temporalité, aux produits, aux magasins et aux clients.

1.3 Analyse des besoins métier

Les décideurs de TechStore ont exprimé des attentes précises concernant les informations qu'ils souhaitent obtenir à partir du système BI. Ces besoins se structurent autour de quatre grandes dimensions analytiques : le temps, le produit, la géographie et le client.

1.3.1 Dimension temporelle

L'analyse temporelle est fondamentale dans tout projet BI car le temps constitue un axe transversal permettant de dégager des tendances. Pour TechStore, les besoins liés au temps sont multiples :

Analyses annuelles, trimestrielles, mensuelles et hebdomadaires

L'entreprise souhaite comprendre comment évoluent ses performances à différentes granularités temporelles. Cela permet de répondre à des questions telles que :

- Comment les ventes de l'année en cours se comparent-elles à celles des années précédentes ?
- Quels sont les trimestres les plus performants ?
- Y a-t-il des variations importantes d'un mois à l'autre ?
- Les ventes du week-end sont-elles meilleures que celles de la semaine ?

Une telle analyse aide à planifier les actions commerciales, organiser les stocks et optimiser les promotions.

Identification des saisons fortes et faibles

Comme toutes les entreprises du secteur électronique, TechStore observe des fluctuations importantes lors de certaines périodes :

- **Saisons fortes** : fêtes de fin d'année, périodes de rentrée, promotions nationales.
- **Saisons faibles** : mois d'été, périodes post-rentree, semaines non promotionnelles.

La BI doit donc permettre d'identifier ces fluctuations afin d'ajuster les campagnes promotionnelles, renforcer les stocks et orienter les investissements publicitaires.

1.3.2 Dimension produit

Les produits sont au cœur de l'activité de TechStore. Le besoin principal des responsables concerne l'analyse approfondie de la performance de chaque produit et de chaque catégorie.

Identification des produits vedettes

Les produits les plus vendus génèrent une grande partie du chiffre d'affaires. Les décideurs doivent pouvoir identifier :

- les best-sellers,
- les produits à rotation rapide,
- les produits en baisse de popularité.

Ces informations influencent directement la gestion des approvisionnements et des stocks.

Analyse de la rentabilité par catégorie

Chaque catégorie (smartphones, ordinateurs, accessoires...) a un impact différent sur le chiffre d'affaires global. L'entreprise a besoin :

- de connaître la contribution de chaque catégorie,
- d'analyser l'équilibre entre produits d'entrée de gamme / haut de gamme,
- de détecter les catégories en croissance ou déclin.

Analyse des marges générées

La marge commerciale est un indicateur clé pour la direction. Un produit peut être très vendu mais faiblement rentable. Le système BI doit donc offrir :

- la marge totale par produit,
- la marge moyenne par catégorie,,
- l'évolution des marges sur le temps.

1.3.3 Dimension géographique

TechStore est implantée dans plusieurs villes et régions. L'analyse géographique est donc fondamentale. En regroupant les magasins par région, la direction peut analyser :

- les zones à forte demande,
- les zones en difficulté,
- les régions à potentiel de croissance.

Analyse des zones à fort potentiel

Une zone peut présenter un faible volume de ventes mais un fort potentiel (ex : grande densité de population, faible concurrence, proximité de centres commerciaux). L'objectif est donc d'anticiper où TechStore devrait investir.

1.3.4 Dimension client

L'analyse client est indispensable pour segmenter les clients et améliorer les stratégies marketing.

Profil des clients rentables

Il s'agit d'identifier les clients générant le plus de revenus :

- clients fidèles,
- clients à forte capacité d'achat,
- clients premium.

Comportement d'achat

TechStore souhaite comprendre :

- les habitudes d'achat (fréquence, panier moyen),
- les catégories préférées,
- la saisonnalité des achats par type de client.

Contribution au chiffre d'affaires

Il est souvent observé que 20 % des clients génèrent 80 % du CA (loi de Pareto). L'entreprise souhaite donc vérifier si ce principe s'applique à son portefeuille clients.

Besoins techniques

En plus des besoins métier, TechStore a exprimé un ensemble d'exigences techniques indispensables pour la réalisation du système BI. Ces besoins concernent principalement l'architecture du système, la qualité des données, la performance des traitements, la sécurité et la traçabilité.

1.3.5 Base OLTP propre et normalisée

Le système opérationnel doit être correctement structuré afin d'éviter les redondances et les incohérences. Une base OLTP normalisée garantit l'intégrité des données et facilite les futures opérations ETL.

1.3.6 Data Warehouse structuré et performant

Le Data Warehouse doit être conçu pour répondre aux besoins d'analyse multidimensionnelle. Il doit :

- * offrir un modèle cohérent (souvent en étoile),
- * permettre des requêtes rapides,
- * conserver l'historique des données,
- * être extensible pour supporter l'évolution future des analyses.

1.3.7 Processus ETL automatisé et robuste

Le pipeline ETL doit être capable :

- * d'extraire les données en minimisant les impacts sur l'OLTP,
- * de nettoyer et standardiser les données,
- * de charger les données dans le Data Warehouse sans erreur,
- * d'effectuer des contrôles de qualité,
- * d'enregistrer des logs d'exécution fiables.

1.3.8 Outil de reporting dynamique

TechStore souhaite des rapports interactifs, faciles à mettre à jour, accessibles et pouvant être rapidement adaptés aux besoins évolutifs des équipes métier. Power BI a été retenu pour sa flexibilité, sa puissance et sa facilité d'intégration.

1.3.9 Sécurité, gouvernance et traçabilité

La sécurité est un besoin transversal. Le système doit garantir :

- * la confidentialité des données clients,
- * la traçabilité des opérations ETL,
- * la gestion des accès par rôle,
- * la fiabilité des données issues du Data Warehouse.

Architecture technique du système BI

1.4 Architecture logique

L'architecture logique définit comment les différentes composantes du système interagissent. La solution BI de TechStore repose sur une chaîne décisionnelle cohérente, organisée en cinq couches distinctes mais interconnectées :

1.4.1 La couche de données opérationnelles (OLTP)

Elle stocke les données brutes issues des opérations quotidiennes de vente. Elle se caractérise par :

- * un modèle normalisé,
- * une grande fréquence de mises à jour,
- * une structure optimisée pour la rapidité d'écriture.

Les utilisateurs métier accèdent rarement à cette couche, car elle n'est pas conçue pour l'analyse.

1.4.2 La couche ETL (Pentaho Data Integration)

Pentaho joue un rôle central dans la chaîne BI. Il permet :

- * d'extraire les données depuis l'OLTP,
- * de les transformer en données propres,
- * de détecter et corriger les anomalies (doublons, valeurs manquantes),
- * d'enrichir les données (calculs, regroupements),
- * de charger le Data Warehouse.

Cette couche assure la qualité des données en sortie.

1.4.3 La couche de stockage décisionnel (Data Warehouse)

Le Data Warehouse représente le cœur du système BI. TechStore y stocke :

- * les données historiques,
- * les mesures agrégées,
- * les dimensions de référence,
- * la table de faits centrale.

Le schéma en étoile permet des analyses rapides grâce à sa structure simplifiée.

1.4.4 La couche analytique (requêtes OLAP)

Cette couche permet :

- * l'exploration multidimensionnelle des données,
- * la production de KPI,
- * la génération d'agrégations par période, produit, région.

Les requêtes OLAP sont optimisées pour des lectures massives.

1.4.5 La couche de visualisation (Power BI)

Elle représente l'interface finale du système BI. Elle permet aux décideurs de :

- * visualiser les indicateurs clés,
- * filtrer les données,
- * explorer les tendances,
- * générer des rapports instantanés.

Power BI rend la solution totalement exploitable par les équipes métier.

1.5 Architecture physique

L'architecture physique décrit la manière dont les outils sont déployés dans l'environnement technique de TechStore.

1.5.1 Serveur MySQL

Le serveur MySQL héberge :

- * la base OLTP,
- * le Data Warehouse.

L'utilisation d'un unique SGBD permet de simplifier les connexions ETL et de réduire les coûts d'infrastructure.

1.5.2 Pentaho installé sur poste local

Pentaho fonctionne sur une machine locale et accède au serveur MySQL.II :

- * exécute les transformations,
- * génère les logs,
- * structure les traitements,
- * permet une gestion modulaire des jobs.

Power BI Desktop

Power BI fonctionne en local pour permettre :

- * la création de rapports interactifs,
- * la mise à jour rapide,
- * l'import direct depuis MySQL.

1.5.3 Fichiers temporaires

Des fichiers CSV sont utilisés pour :

- * charger des données brutes,
- * tester des flux ETL,
- * comparer des résultats intermédiaires.


Modélisation OLTP

1.6 Importance du modèle OLTP

La modélisation OLTP est essentielle, car elle conditionne l'efficacité du futur système BI. Une base mal conçue entraîne :

- problèmes d'intégrité,
- lenteur des ETL,
- analyses incorrectes,
- instabilité générale du système.

1.7 Tables utilisées



Conception du Data Warehouse

1.8 Rôle du Data Warehouse

Le Data Warehouse constitue la base du système décisionnel. Il permet :

- l'intégration des données provenant de l'OLTP,
- la structuration en schéma en étoile,
- l'historisation,
- l'analyse multidimensionnelle,
- l'optimisation des requêtes analytiques.

Un Data Warehouse bien conçu améliore fortement la qualité du reporting et des analyses.

1.9 Modèle en étoile

Le schéma en étoile est une modélisation multidimensionnelle largement utilisée dans les Data Warehouses pour organiser les données en vue d'analyses rapides et intuitives. Dans le contexte de ton TP TechStore, où seules les tables clients, produits et ventes existent dans l'OLTP, et où une dimension date est créée à partir des dates de vente, le schéma en étoile est parfaitement adapté : il permet de transformer la structure transactionnelle en un modèle optimisé pour les requêtes analytiques, les regroupements et les agrégations.

L'idée centrale du schéma en étoile est simple : une table de faits contenant les mesures est reliée à plusieurs dimensions descriptives. Ce découpage favorise la lisibilité, simplifie les jointures et accélère les requêtes analytiques. La section suivante détaille la structure proposée, explique pourquoi ce choix est pertinent pour ton TP et donne des recommandations pratiques pour optimiser les performances.

- une table de faits : **FaitsVentes**,
- plusieurs tables de dimensions :
 - DimProduit,
 - DimClient,
 - DimTemps.

1.9.1 Table DimTemps

Contient :

- année,
- trimestre,
- mois,
- semaine,
- jour.

Intérêt analytique :

- * analyses mensuelles, trimestrielles, annuelles,
- * étude des tendances,
- * mesure de la saisonnalité,
- * détection des périodes de pointe.

1.9.2 Table DimProduit

- nom du produit,
- catégorie,
- marque,
- prix catalogue.

Elle permet de :

- * identifier les produits les plus vendus,
- * comparer les catégories,
- * analyser la performance des marques,
- * calculer les marges,
- * suivre l'évolution du catalogue.

1.9.3 Table DimClient

- nom,
- email,
- ville,
- pays,
- segment client.

Elle permet d'étudier :

- * quels segments achètent le plus,
- * les villes qui génèrent le plus de chiffre d'affaires,
- * le profil des clients rentables,
- * les tendances démographiques.
-

1.9.4 FaitsVentes

Contient les mesures :

- quantités vendues,
- chiffre d'affaires,
- marge,
- réductions éventuelles.

Chaque enregistrement est lié aux dimensions via des clés étrangères.

1.10 Justification complète du choix du schéma en étoile

1.10.1 Simplicité et lisibilité

Le schéma en étoile sépare clairement les mesures (faits) et les contextes (dimensions). Pour les analystes ou enseignants qui liront ton rapport, la structure est directe : on comprend immédiatement que les ventes sont expliquées par qui (client), quoi (produit) et quand (date). Pour un TP, cette lisibilité est un avantage pédagogique majeur.

1.10.2 Performance des requêtes analytiques

Les requêtes analytiques (agrégations, group by, top N, filtres temporels) sont plus rapides sur un schéma en étoile car : * Les jointures sont entre la table de faits (large) et les petites dimensions (compactes), ce qui est plus efficace que des jointures entre plusieurs tables OLTP normalisées. * Les dimensions étant dénormalisées, on évite des séries de jointures coûteuses.

1.10.3 Correspondance avec les outils BI

Power BI et autres outils de visualisation comprennent naturellement ce type de modélisation. Ils permettent de créer facilement des relations entre faits et dimensions, configurer des hiérarchies temporelles et bâtir des slicers/filters. Pour ton TP, utiliser un schéma en étoile simplifie le développement des rapports.

1.10.4 Facilité d'évolution

Même si votre TP est simple, le schéma en étoile permet d'ajouter ultérieurement d'autres dimensions (si nécessaire) sans refondre la table de faits. Il suffit d'ajouter une nouvelle petite table de dimension et d'y faire référence.

1.11 Avantages analytiques concrets pour TechStore (exemples applicables au TP)

Voici des exemples d'analyses rendues simples et rapides par le schéma en étoile :

- * **Chiffre d'affaires par mois pour un produit donné** : on filtre $\text{dim}_{\text{produit}}$, on joint $\text{fait}_{\text{ventes}}$, puis on agrège par $\text{dim}_{\text{date.mois}}$.
- * **Top 10 des clients par montant total** : agrégation $\text{SUM}(\text{montant})$ groupée par $\text{dim}_{\text{client}}$.
- * **Évolution temporelle des ventes d'une catégorie** : si categorie existe dans $\text{dim}_{\text{produit}}$, on peut tracer une courbe mois par mois.
- * **Panier moyen par client** : $\text{SUM}(\text{montant}) / \text{COUNT}(\text{DISTINCT id}_{\text{facture}})$ (situation d'information), ou $\text{SUM}(\text{montant}) / \text{COUNT}(\text{DISTINCT id}_{\text{client}})$.

Ces analyses sont pédagogiques et directement applicables à ton TP sans ajout d'autres tables.

Pipeline ETL Détaillé

Le pipeline ETL (Extraction – Transformation – Chargement) représente l'ensemble des étapes nécessaires pour transférer les données depuis la base OLTP (MySQL) vers le Data Warehouse. Pentaho Data Integration (PDI / Spoon) est utilisé dans votre TP pour automatiser ce processus. Voici une explication détaillée de chaque étape.

1.12 EXTRACTION (E)

L'extraction est la première phase. Elle consiste à récupérer les données brutes directement depuis les tables de la base OLTP. Dans votre TP, vous avez extrait les données suivantes :

- * La table clients
- * La table produits
- * La table ventes

Pentaho se connecte à MySQL grâce à :

- * une connexion JDBC,
- * un database connection configuré dans PDI (host, port, user, password).

Le but de l'extraction est simplement de lire les données sources sans les modifier. À cette étape, il n'y a pas encore de filtrage, pas de calcul, pas de transformation.

Les composants Pentaho utilisés :

- * Table Input
- * Database Lookup (si utilisé pour vérifications)

L'extraction doit être rapide, fiable et ne pas impacter la base OLTP.

1.13 TRANSFORMATION (T)

C'est l'étape la plus importante du pipeline ETL. Elle consiste à nettoyer, enrichir, harmoniser et préparer les données pour qu'elles puissent être intégrées dans le Data Warehouse.

Dans votre TP, les transformations classiques ont été :

Nettoyage

- * suppression des champs vides,
- * contrôle des valeurs nulles (NOT NULL),
- * exclusion des ventes invalides (ex : quantité < 1).

Standardisation

- * uniformisation des dates,
- * typage correct des colonnes (INT, VARCHAR, DECIMAL),
- * conversion de formats (string → date, etc.).

Enrichissement

- * génération de la dimension Date à partir de $date_{vente}$,
- * calcul du montant de la vente : $\rightarrow \text{montant} = \text{quantite} * \text{prix}$

Mapping

Le mapping consiste à faire correspondre les colonnes *OLTP* aux colonnes *DWH*

1.14 CHARGEMENT (L)

Le chargement consiste à insérer les données transformées dans les tables du Data Warehouse. L'ordre est très important :

1.14.1 Chargement des dimensions

Toujours charger les dimensions avant la table des faits :

- * dim_{client}
- * $dim_{produit}$
- * dim_{date}

Le chargement met à jour ou ajoute :

- * les nouvelles entrées,
- * les modifications (SCD Type 1 : écrasement),
- * les clés substitués.

1.14.2 Chargement de la table des faits

Une fois les dimensions prêtes, Pentaho charge : $fait_{ventesEllecontient}$:

- * fk_{client}
- * $fk_{produit}$
- * fk_{date}
- * quantite
- * montant

Le fait ne doit être chargé qu'avec des valeurs entièrement propres et validées.

1.15 LOGS D'EXÉCUTION

Les logs permettent de suivre le fonctionnement de l'ETL. Pentaho génère trois types de logs :

1.15.1 Log de transformation

- * nombre de lignes lues,
- * nombre de lignes écrites,
- * durée d'exécution,
- * étapes ayant échoué.

1.15.2 Log d'erreurs

- * lignes refusées,
- * connexions échouées,
- * problèmes de typage.

1.15.3 Log de performance

- * temps passé par étape,
- * vitesse de traitement (lignes/sec).

Ces logs sont essentiels pour vérifier que l'ETL s'exécute correctement.

1.16 GESTION DES ERREURS

Dans Pentaho, la gestion des erreurs est essentielle pour éviter que l'ETL ne s'arrête brutalement. Les mécanismes utilisés :

1.16.1 Error Handling

Sur chaque étape sensible :

- * Table Input
- * Table Output
- * Insert/Update

Pentaho envoie les lignes problématiques vers :

- * une table de rejet,
- * un fichier CSV d'erreurs,
- * un flux parallèle.

1.16.2 Exemples d'erreurs gérées

- * clé étrangère manquante,
- * date invalide,
- * type incompatible,
- * prix négatif ou quantité invalide.

1.16.3 Action en cas d'erreur

Le système :

- * log l'erreur,
- * ignore uniquement la ligne fautive,
- * continue l'exécution du job.

Ce comportement garantit la stabilité du pipeline.

1.16.4 CONTRÔLES QUALITÉ

Avant de charger les données, plusieurs contrôles qualitatifs sont indispensables :

Contrôle d'unicité

Vérifier que :

- * un client n'existe pas deux fois dans dim_{client} ,
- * un produit n'est pas dupliqué dans $dim_{produit}$.

Contrôle d'intégrité

Vérifier que :

- * *fk_client_existedansdim_client*,
- * *fk_produit_existedansdim_produit*.

Contrôle de complétude

Aucune valeur importante ne doit être NULL :

- * *id_client*
- * *id_produit*
- * *date_vente*
- * *quantite*

Pentaho permet d'ajouter ces contrôles avec :

- * "Filter Rows"
- * "Validator"
- * "Modified Java Script"

1.16.5 AUTOMATISATION

Dans votre TP, vous pouvez automatiser l'ETL grâce à des Jobs Pentaho, qui regroupent plusieurs transformations.

Fonctionnalités d'automatisation

- * lancer l'ETL chaque jour / semaine,
- * utiliser un "Start" et un "Success / Fail" dans Pentaho,
- * redémarrer automatiquement en cas d'erreur,
- * envoyer un email en cas d'échec (optionnel).

Donc en récapitulant voilà un résumé :

- *Extraction* : lire les tables source (clients, produits, ventes)
- *Transformation* : nettoyer, normaliser, calculer les montants, générer dates et clés
- *Chargement* : remplir les dimensions puis la table des faits
- *Logs* : suivre l'exécution
- *Gestion d'erreurs* : isoler les lignes impossibles
- *Contrôles qualité* : valider la cohérence
- *Automatisation* : rendre l'ETL exécutable automatiquement

Analyses OLAP

L'objectif des analyses OLAP est d'exploiter pleinement le Data Warehouse construit afin de permettre à TechStore d'obtenir une vision claire, détaillée et multiaxiale de son activité commerciale. Grâce au schéma en étoile ($dim_{clients}$, $dim_{produits}$, $dim_{magasins}$, dim_{date} et $fact_{ventes}$), il devient possible d'analyser les performances de l'entreprise en fonction du temps, des produits, des clients et de la géographie.

Les analyses OLAP permettent :

- * de détecter des tendances,
- * d'identifier les produits performants ou non,
- * de mieux comprendre le comportement des clients,
- * d'évaluer les performances des magasins.

La logique OLAP repose essentiellement sur quatre opérations principales :

- * Drill-down (descendre dans le détail),
- * Roll-up (agréger),
- * Slice (extraire un sous-ensemble),
- * Dice (combiner plusieurs filtres).

1.17 Analyses temporelles

L'analyse temporelle est l'une des plus importantes car elle permet de comprendre l'évolution de l'activité commerciale de TechStore sur plusieurs périodes. Grâce à la dimension Date, l'utilisateur peut analyser les ventes par :

- comparer les ventes par année,
- observer les tendances trimestrielles,
- analyser la saisonnalité mensuelle,
- identifier les jours et semaines à fort rendement.

1.18 Analyses produits

L'analyse produit permet de comprendre la performance commerciale de chaque référence, catégorie ou marque. Elle s'appuie sur la dimension Produit, qui inclut :

- produits les plus vendus,
- produits les plus rentables,
- comparaison entre catégories,
- analyse des marges.

1.19 Analyses clients

L'objectif est d'analyser le comportement des clients : localisation, sexe, âge (si disponible), segment, fréquence d'achat.

- clients les plus rentables,
- taux de réachat,

- panier moyen,
- contribution au chiffre d'affaires total.

1.20 Analyses géographiques

On peut d'après ces données retirer ce qui est important pour nous, comme :

- comparaison des magasins,
- performance par région,
- détection des zones à fort potentiel,
- corrélation entre localisation et chiffre d'affaires.

Chapitre 2

Visualisations Power BI

L'utilisation de Power BI permet de transformer les données du Data Warehouse en visualisations simples, lisibles et interactives. Les tableaux de bord permettent aux décideurs de TechStore de prendre des décisions rapides basées sur des informations fiables.

2.1 KPI mis en avant

Les KPI les plus pertinents pour TechStore sont :

- * CA Total
- * Quantité totale vendue
- * Nombre de clients actifs
- * Nombre de transactions
- * Panier moyen
- * Top produit

Ces KPI apparaissent en haut du dashboard sous forme de cartes, afin de pouvoir être immédiatement interprétés.

2.2 Graphiques utilisés

2.2.1 Graphique en courbes

Pour visualiser :

- * le CA par mois,
- * les tendances annuelles.

2.2.2 Graphiques en barres

Pour comparer :

- * les ventes par catégorie,
- * les ventes par ville,
- * les marques les plus vendues.

2.2.3 Treemap

Pour analyser :

- * la répartition des ventes par produit,
- * la part des catégories dans le CA.

2.2.4 Carte géographique

Pour visualiser les ventes par région ou par ville.

2.2.5 Diagrammes circulaires

Pour analyser la part d'une catégorie ou marque sur un total.

2.2.6 Interactions

Power BI permet une navigation fluide grâce à :

- * le cross-filtering (cliquer sur un élément filtre tout le dashboard),
- * le drill-down (descendre du niveau "année" au niveau "mois"),
- * le drill-through (accéder au détail par magasin ou par client),
- * les tooltips personnalisés (informations affichées au survol).

Ces interactions permettent d'obtenir une analyse très dynamique, sans quitter le dashboard.

2.2.7 Segments (Slicers)

Les segments permettent de filtrer le dashboard par :

- * année,
- * mois,
- * catégorie,
- * produit,
- * ville,

Un utilisateur peut par exemple afficher uniquement les ventes :

- * d'une ville,
- * d'un mois précis,
- * d'un produit particulier.

2.2.8 Interprétation métier

Les visualisations Power BI permettent de :

- * identifier les zones problématiques,
- * surveiller les magasins sous-performants,
- * détecter les produits en tendance,
- * anticiper les ruptures de stock,
- * ajuster les campagnes marketing.

2.3 Interactions

- filtres dynamiques,
- segments de dates,
- navigation entre pages,
- survols interactifs,
- drill-down et drill-through.

Conclusion

Cette conclusion résume l'ensemble du projet, ses apports, ses limites et les perspectives possibles pour TechStore.

Synthèse du projet

Le projet BI a permis :

- une meilleure compréhension de la performance commerciale,
- une vision consolidée des ventes, produits, clients,
- une automatisation du processus d'analyse,
- la mise en place d'un reporting fiable et maintenable,
- une prise de décision plus rapide et mieux informée.

Limites du projet

Certaines limites existent :

- * absence de données réelles (données générées),
- * manque de certaines dimensions avancées (fournisseurs, promotions, etc.),
- * pipeline ETL encore manuel,
- * absence de mesures financières avancées (marge réelle).



Le projet constitue une base solide pour une extension future :


Perspectives stratégiques

Le projet constitue une base solide pour une extension future : * automatisation complète de l'ETL, * ajout d'une dimension Promotion, * intégration des données web (clics, navigation, visites), * mise en place d'analyses prédictives (Machine Learning), * création d'un système de recommandation, * segmentation client avancée.



Captures d'écran

Partie : MySQL





Partie : PDI



Spoon - dim_client

Design

Input

Output

Automatic documentation

Delete

Insert / update

JSON output

LDAP output

Microsoft Access output

Microsoft Excel writer

Pentaho reporting output

Properties output

RSS output

S3 file output

SQL file output

Salesforce delete

Salesforce insert

Salesforce update

Salesforce upsert

Serialize to file

Synchronize after merge

Table output

Text file output

Update

XML output

Streaming

Transform

Utility

Flow

Execution Results

Logging Execution History Step Metrics Performance Graph Metrics Preview data

#	Stepname	Copynr	Read	Written	Input	Output	Updated	Rejected	Errors	Active	Time	Speed (r/s)	input/output
1	Lecture_Clients_OLTP	0	0	10000	10000	0	0	0	0	Finished	0.0s	285,714	-
2	Lecture_Produts_OLTP	0	0	500	500	0	0	0	0	Finished	0.0s	38,462	-
3	Renommer_Colones	0	500	500	0	0	0	0	0	Finished	0.0s	33,333	-
4	Renommer_Colones	0	10000	10000	0	0	0	0	0	Finished	0.0s	263,158	-
5	Ecriture_DimClient	0	10000	10000	0	10000	0	0	0	Finished	0.5s	20,964	-
6	Ecriture_DimProduits	0	500	500	0	500	0	0	0	Finished	0.1s	7,042	-

Spoon - dim_client (changed)

Modified JavaScript value

Step name Modified JavaScript value

Java script functions :

- Transform Scripts
- Transform Constants
- Transform Functions
- Input fields
 - compteur
 - numero_jour
- Output fields

Please use the 'Replace' button to replace the value of the field.

Script 1 X

```
Cr  er la date de base (1er janvier 2022)
date_base = new Date(2022, 0, 1);

Ajouter le nombre de jours
date_base.setDate(date_base.getDate() + numero_jour);

Cr  er la date compl  te
date_complete = date_base;

Extraire les composantes
annee = date_base.getFullYear();
mois = date_base.getMonth() + 1;
jour = date_base.getDate();

Position: 27,4
Compatibility mode? Optimization level 9
```

#	Fieldname	Rename to	Type	Length	Precision	Replace value 'Fieldname' or 'Rename to'
1	date_base		Date			N
2	date_complete		Date			N
3	annee		Number	16	2	N
4	mois		Number	16	2	N
5	jour		Number	16	2	N
6	trimestre		Number	16	2	N
7	jour_semaine		Number	16	2	N
8	id_date_dim		Number	16	2	N
9	noms_mois		String			N
10	nom_mois		String			N
11	noms_jours		String			N
12	nom_jour		String			N

Help OK Cancel Get variables Test script

Spoon - dim_client (changed)

Connect

View Design

Search

Input

Output

Automatic documentat

Delete

Insert / update

JSON output

LDAP output

Microsoft Access outp

Microsoft Excel writer

Pentaho reporting outp

Properties output

RSS output

S3 file output

SQL file output

Salesforce delete

Salesforce insert

Salesforce update

Salesforce upsert

Serialize to file

Synchronize after merg

Table output

Text file output

Update

XML output

Streaming

Transform

Utility

Flow

Scripting

Welcome!

dim_client

100%

Lecture_Clients_OLTP

Renommer_Colones

Ecriture_DimClient

Ecriture_DimDate

Lecture_Produits_OLTP

Renommer_Colones

Ecriture_DimProduits

Select values

Generer_Lignes

Ajouter_Sequence

Modified JavaScript value

Execution Results

Logging

Execution History

Step Metrics

Performance Graph

Metrics

Preview data

#	Stepname	Copynr	Read	Written	Input	Output	Updated	Rejected	Errors	Active	Time	Speed (r/s)	Input/output
1	Generer_Lignes	0	0	1096	0	0	0	0	0	Finished	0.0s	1,096,000	-
2	Lecture_Clients_OLTP	0	0	10000	10000	0	0	0	0	Finished	0.0s	250,000	-
3	Ajouter_Sequence	0	1096	1096	0	0	0	0	0	Finished	0.0s	219,200	-
4	Lecture_Produits_OLTP	0	0	500	500	0	0	0	0	Finished	0.0s	21,739	-
5	Modified JavaScript valu	0	1096	1096	0	0	0	0	0	Finished	0.0s	57,684	-
6	Renommer_Colones	0	10000	10000	0	0	0	0	0	Finished	0.0s	232,558	-
7	Renommer_Colones	0	500	500	0	0	0	0	0	Finished	0.0s	20,000	-
8	Ecriture_DimProduits	0	500	500	0	500	0	0	0	Finished	0.1s	3,472	-
9	Select values	0	1096	1096	0	0	0	0	0	Finished	0.0s	52,190	-
10	Ecriture_DimDate	0	1096	1096	0	1096	0	0	0	Finished	0.2s	5,535	-
11	Ecriture_DimClient	0	10000	10000	0	10000	0	0	0	Finished	0.8s	12,771	-

MySQL Workbench

Local instance 3306 - Warning - not supported

Schemas

create_oltp*

create_dwh

SQL File 5*

Limit to 1000 rows

1

2

SELECT *

FROM ventes_dwh.DimDate

ORDER BY date_complete

LIMIT 10;

100%

1-2

Result Grid

Filter Rows:

Search

Edit

Export/Import:

Fetch rows:

id_date_dim	date_complete	annee	trimestre	mois	nom_mois	jour	jour_semaine	nom_jour
20220102	2022-01-02	2022	1	1	Janvier	2	7	Dimanche
20220103	2022-01-03	2022	1	1	Janvier	3	1	Lundi
20220104	2022-01-04	2022	1	1	Janvier	4	2	Mardi
20220105	2022-01-05	2022	1	1	Janvier	5	3	Mercredi
20220106	2022-01-06	2022	1	1	Janvier	6	4	Jeudi
20220107	2022-01-07	2022	1	1	Janvier	7	5	Vendredi
20220108	2022-01-08	2022	1	1	Janvier	8	6	Samedi
20220109	2022-01-09	2022	1	1	Janvier	9	7	Dimanche
20220110	2022-01-10	2022	1	1	Janvier	10	1	Lundi

Session

create_dwh

Action Output

Time

Action

Response

20	06:26:00	CREATE TABLE DimClient (id_client_dim INT AUTO_INCREMENT PRIMARY KEY, id_client_source INT NOT NULL, no...	0 row(s) affected
21	06:26:00	CREATE TABLE DimProduit (id_produit_dim INT AUTO_INCREMENT PRIMARY KEY, id_produit_source INT NOT NULL, ...	0 row(s) affected
22	06:26:00	CREATE TABLE DimDate (id_date_dim INT PRIMARY KEY, date_complete DATE NOT NULL UNIQUE, annee INT NOT ...	0 row(s) affected
23	06:26:00	CREATE TABLE FactVentes (id_vente INT AUTO_INCREMENT PRIMARY KEY, id_client_dim INT NOT NULL, id_produi...	0 row(s) affected
24	06:26:00	SHOW TABLES	4 row(s) returned
25	06:26:00	DESCRIBE DimClient	5 row(s) returned
26	06:26:00	DESCRIBE DimProduit	4 row(s) returned
27	06:26:00	DESCRIBE DimDate	9 row(s) returned
28	06:26:00	DESCRIBE FactVentes	7 row(s) returned

Welcome! transformations_tp X 75%

Execution Results

Logging Execution History Step Metrics Performance Graph Metrics Preview data

#	Stepname	Copynr	Read	Written	Input	Output	Updated	Rejected	Errors Active	Time	Speed (r/s)	input/output
1	Renommer_Colones	0	0	0	0	0	0	0	0 Finished	0.0s	-	-
2	Generer_Lignes	0	0	1096	0	0	0	0	0 Finished	0.0s	1,096,000	-
3	Ajouter_Sequence	0	1096	1096	0	0	0	0	0 Finished	0.0s	274,000	-
4	Lecture_Lignes_Commande	0	0	100000	100000	0	0	0	0 Finished	6.7s	14,910	-
5	Lecture_Produits_OLTP	0	0	500	500	0	0	0	0 Finished	0.0s	16,667	-
6	JavaScript	0	1096	1096	0	0	0	0	0 Finished	0.0s	60,889	-
7	Lookup_Client	0	100000	0	0	0	0	0	0 Finished	7.4s	13,585	-
8	Lookup_Produit	0	0	0	0	0	0	0	0 Finished	7.4s	0	-
9	Renommer_Colones	0	500	500	0	0	0	0	0 Finished	0.0s	15,625	-
10	Ecriture_DimProduits	0	500	500	0	500	0	0	0 Finished	0.1s	4,762	-
11	Select values	0	1096	1096	0	0	0	0	0 Finished	0.0s	54,800	-
12	Ecriture_DimDate	0	1096	1096	0	1096	0	0	0 Finished	0.2s	7,258	-
13	Lookup_Date	0	0	0	0	0	0	0	0 Finished	7.4s	0	-
14	Calculer_Montant	0	0	0	0	0	0	0	0 Finished	7.4s	0	-
15	Select values 2	0	0	0	0	0	0	0	0 Finished	7.4s	0	-
16	Ecriture_FactVentes	0	0	0	0	0	0	0	0 Finished	7.4s	0	-
17	Ecriture_DimClient	0	0	0	0	0	0	0	0 Finished	0.0s	0	-

```

olap_results.txt
nbre_clients nombre_ventes
} 9283
17 neta
1
(base) nadezzouhour@NADAC ~ % nano olap_queries.sql
(base) nadezzouhour@NADAC ~ % mysql -u root -p < olap_queries.sql
Enter password:

```

olap_results.txt

ville	chiffre_affaires	nombre_clients	nombre_ventes
Montpellier	27578518.00	748	9203
Rennes	26750345.00	781	8837
Bordeaux	26202469.00	732	8530
Nice	25648124.00	729	8523
Marseille	25194253.00	729	8379
Strasbourg	25116260.00	711	8355
Lille	24826726.00	729	8398
Nantes	24617534.00	718	8094
Lyon	24486553.00	713	8227
Reims	24439394.00	733	8182
Toulouse	23372469.00	676	7711
Paris	23064843.00	656	7543
ville	59206.00	1	18

categorie	chiffre_affaires	quantite_vendue	nombre_produits_distincts	prix_moyen
Ordinateurs	64769877.00	59965	99	1079.15
Téléphones	64526264.00	60122	100	1072.42
Accessoires	60129964.00	60127	100	1000.07
Tablettes	56774487.00	59296	100	953.92
Montres	55100653.00	59737	100	919.41

categorie	annee	mois	chiffre_affaires	nombre_ventes	panier_moyen
2022	1	Janvier	8897711.00	3003	2962.94
2022	2	Février	8141180.00	2655	3066.36
2022	3	Mars	8611136.00	2892	2977.57
2022	4	Avril	8364191.00	2767	3022.84
2022	5	Mai	7941259.00	2705	2935.77
2022	6	Juin	8000701.00	2602	3074.83
2022	7	Juillet	8454878.00	2887	2928.60
2022	8	Août	8361499.00	2740	3051.64
2022	9	Septembre	8268176.00	2717	3043.13
2022	10	Octobre	8026616.00	2688	2986.09
2022	11	Novembre	8328418.00	2760	3017.54
2022	12	Décembre	8354504.00	2770	3016.07
2023	1	Janvier	8117832.00	2647	3066.80
2023	2	Février	7096489.00	2381	2980.47
2023	3	Mars	8258813.00	2724	3031.87
2023	4	Avril	8348129.00	2724	3064.66
2023	5	Mai	8199004.00	2760	2970.65
2023	6	Juin	7898658.00	2638	2994.18
2023	7	Juillet	8413453.00	2830	2972.95
2023	8	Août	8274841.00	2808	2946.88
2023	9	Septembre	7636479.00	2464	3099.22
2023	10	Octobre	8139580.00	2706	3007.97
2023	11	Novembre	8817859.00	2937	3002.34
2023	12	Décembre	8315766.00	2769	3003.17
2024	1	Janvier	8814160.00	2842	3101.39
2024	2	Février	8560754.00	2847	3006.94
2024	3	Mars	8688465.00	2867	3030.51
2024	4	Avril	8070828.00	2709	2979.26
2024	5	Mai	9264065.00	3058	3029.45
2024	6	Juin	8183324.00	2707	3023.02
2024	7	Juillet	8628519.00	2830	3048.95
2024	8	Août	9506839.00	3081	3085.63
2024	9	Septembre	8286686.00	2797	2962.71
2024	10	Octobre	9092226.00	3100	2932.98
2024	11	Novembre	7820210.00	2581	3033.40
2024	12	Décembre	9164436.00	3007	3047.70

nom_produit	categorie	quantite_totale_vendue	chiffre_affaires	prix_moyen
Apple Watch Plus	Montres	751	1334527.00	1776.81
Clavier mécanique Ultra	Accessoires	740	1277240.00	1726.43
Huawei MatePad Lite	Tablettes	734	136524.00	186.37
Xiaomi 13 Plus	Téléphones	725	1046175.00	1442.98
HP Pavilion Plus	Ordinateurs	714	369852.00	518.16
iPhone 14 Standard	Téléphones	707	1260581.00	1782.59
Asus VivoBook Ultra	Ordinateurs	704	1265792.00	1797.82
Garmin Forerunner Lite	Montres	704	772992.00	1097.54
Webcam HD Ultra	Accessoires	703	1120582.00	1594.23
OnePlus 11 Standard	Téléphones	702	819234.00	1167.47

annee	trimestre	categorie	chiffre_affaires	quantite_vendue
2022	1	Téléphones	5474825.00	5004
2022	1	Ordinateurs	5374398.00	5007
2022	1	Accessoires	5157471.00	5135
2022	1	Tablettes	4935860.00	5287
2022	1	Montres	4699999.00	5208
2022	1	categorie	7474.00	74
2022	2	Ordinateurs	5568016.00	5131
2022	2	Téléphones	5493563.00	5091
2022	2	Accessoires	4660607.00	4617
2022	2	Tablettes	4307000.00	4516

MySQL Workbench

Local instance 3306 - Warning - not supported

Schemas

Administration

Schemas

create_oltp*

create_dwh

olap_queries

Limit to 1000 rows

1

USE ventes_dwh;

2

--

3

Requête 1 : Chiffre d'affaires par ville

4

SELECT

5

c.ville,

6

SUM(f.montant_total) AS chiffre_affaires,

7

COUNT(DISTINCT f.id_client_din) AS nombre_clients,

8

COUNT(f.id_vente) AS nombre_ventes

9

FROM FactVentes f

10

INNER JOIN DimClient c ON f.id_client_din = c.id_client_din

11

GROUP BY c.ville

12

ORDER BY chiffre_affaires DESC;

13

Result Grid

Filter Rows: Q Search

Export

annee	trimestre	categorie	chiffre_affair...	quantite_vend...
2022	1	Téléphones	5474825.00	5004
2022	1	Ordinateurs	5374398.00	5007
2022	1	Accessoires	5157471.00	5135
2022	1	Tablettes	4935860.00	5287

Object Info

Session

Action Output

Action

Response

Duration / Fetch Time

1	16:59:08	SELECT	d.annee, d.trimestre, p.categorie, SUM(f.montant_total) AS chiffre_affaires, SUM(f.quantite) AS quantite...	Error Code: 1046. No database selected Select the de...	0.00097 sec
2	16:59:11	USE	ventes_dwh	0 row(s) affected	0.00016 sec
3	16:59:11	SELECT	c.ville, SUM(f.montant_total) AS chiffre_affaires, COUNT(DISTINCT f.id_client_din) AS nombre_clients, C...	13 row(s) returned	0.145 sec / 0.000017...
4	16:59:11	SELECT	p.categorie, SUM(f.montant_total) AS chiffre_affaires, SUM(f.quantite) AS quantite_vendue, COUNT(DIST...	6 row(s) returned	0.124 sec / 0.000042...
5	16:59:11	SELECT	d.annee, d.mois, d.nom_mois, SUM(f.montant_total) AS chiffre_affaires, COUNT(DISTINCT f.id_vente) AS nombre...	36 row(s) returned	0.182 sec / 0.000034...
6	16:59:12	SELECT	p.nom_produit, p.categorie, SUM(f.quantite) AS quantite_totale_vendue, SUM(f.montant_total) AS chiffre...	10 row(s) returned	0.210 sec / 0.000007...
7	16:59:12	SELECT	d.annee, d.trimestre, p.categorie, SUM(f.montant_total) AS chiffre_affaires, SUM(f.quantite) AS quantite...	72 row(s) returned	0.256 sec / 0.000004...
8	17:00:29	SELECT	d.annee, d.trimestre, p.categorie, SUM(f.montant_total) AS chiffre_affaires, SUM(f.quantite) AS quantite...	72 row(s) returned	0.277 sec / 0.000100...

SQL script saved to 'I:\Users\hadzezzouhou\Documents\olap_queries.sql'

Partie Power BI

